

Końcowy raport - modele predykcyjne

Wstęp

Autorstwo

Raport jest cały pisany ręcznie. A.I zostało użyte do formatowania tekstu, częściowo wyprowadzania równań (wszystkie są przejrane ręcznie), oraz do napisania konstrukcji eksperymentu (tylko szarlatan by to pisał ręcznie).

Cel

Celem analizy jest wybranie najlepszej konstrukcji, związanej z modelem predykcyjnym. Porównuje tutaj różne regularyzacje odnosząc się do podstaw teoretycznych.

Celem jest także zrobienie takiego wstępu teoretycznego, żeby Maria baze związaną co było robione.

Sugestia

Rzucić okiem na eksperyment, najważniejsze jest, że: - wszystkie model miały te same datasey treningowe, więc nie ma różnicy ze względu na dane - architektura użyta do rekonstrukcji to sieć konwolucyjna z binnigiem $\Delta m \setminus z$. - testujemy różne funkcje kosztu, sprawdzamy - kontraktywność (to mi zajęło większość czasu, ponieważ mamy inny przypadek niz w oryginalnym artykule)

- kontrastywność - w teorii rzucić okiem na: - przestrzeń i że jest to podrozmaitość S^8 przekształcona przez odwzorowanie afiniczne. - kontraktywność - wnioski z parmatarami i powody pomiaru - nnPU i ogólnie problematyke klas

Konstrukcja eksperymentu

Architektura

Wszystkie 35 przebiegów używa tych samych czterech komponentów, różniąc się wyłącznie członami straty nałożonymi na ich wyjścia.

Enkoder

Trzy bloki konwolucyjne `Conv1d` → `LayerNorm` → `ReLU`, następnie wąskie gardło `Flatten` → `Linear` → `LayerNorm`. Liczba kanałów rośnie, a następnie maleje, natomiast oś widmowa kurczy się przy każdym kroku:

etap	operacja	kanały	kernel	stride	szerokość wyjścia
wejście	—	1	—	—	1273
blok 1	<code>Conv1d</code> + <code>LayerNorm</code> + <code>ReLU</code>	1 → 32	5	3	423

etap	operacja	kanały	kernel	stride	szerokość wyjścia
blok 2	Conv1d + LayerNorm + ReLU	32 → 16	7	3	139
blok 3	Conv1d + LayerNorm + ReLU	16 → 8	3	3	46
projekcja	Flatten(8 × 46 = 368) → Linear(368, 10) → LayerNorm	—	—	—	$L = 10$

Architektura jest analogiczna do analizy rekonstrukcyjnej, przy czym zmieniłem rozmiar pierwszego i drugiego filtra. Liczba parametrów pozostała ta sama, więc nie wprowadza to dodatkowej zmienności, a celem było zmniejszenie szumu wynikającego z długości obwiedni.

Uwaga: Wszystkie normalizacje to `LayerNorm`, nie `BatchNorm`. Jest to wymóg kary kontraktywnej: przy `BatchNorm` Jakobian $\partial \text{enc}(x)/\partial x$ zależałby od pozostałych elementów batcha przez statystyki bieżące, więc nie byłby dobrze określony jako pochodna funkcji pojedynczej próbki.

Dekoder

Odbicie lustrzane enkodera. `Linear → LayerNorm → Reshape` rozwija kod L -wymiarowy z powrotem do kształtu $(8, 46)$, następnie trzy bloki `ConvTranspose1d` w odwrotnej kolejności kanałów $(8 \rightarrow 16 \rightarrow 32 \rightarrow 1)$, z tymi samymi kernelami i strideami) odtwarzają szerokość $M = 1273$. Wartość `output_padding` w każdym bloku jest dobrana tak, żeby szerokość wyjścia zgadzała się dokładnie z odpowiadającą szerokością wejścia enkodera, więc nie ma przycinania.

Każdy blok poza ostatnim to `ConvTranspose1d → LayerNorm → ReLU`. Ostatni to `ConvTranspose1d → softplus → normalizacja TIC`, gdzie `softplus` wymusza nieujemne intensywności, a normalizacja TIC sprowadza rekonstrukcję na tę samą skalę co wejście.

Projektor

`Linear(10, 10) → LayerNorm → ReLU → Linear(10, 64)`. Odwzorowuje kod z na osobną projekcję $g(z)$, używaną wyłącznie przez stratę kontrastyczną.

Głowa klasyfikacyjna

`Linear(10, 128) → ReLU → Dropout(0.1) → Linear(128, 508)`, działa na z . Zwraca surowe logity, nie prawdopodobieństwa, ponieważ sigmoidy i softplus są stosowane wewnątrz implementacji strat głowy, co daje stabilniejszy numerycznie rachunek.

Badane ablacje

Jedna architektura $\times$ siedem kompozycji straty $\times$ pięć powtórzeń = 35 zadań.

$$L = \lambda_{\text{rec}} L_{\text{rec}} + \lambda_{\text{cls}} L_{\text{head}} + \lambda_{\text{CAE}} L_{\text{contractive}} + \lambda_{\text{NCE}} L_{\text{NCE}}$$

grid_id	etykieta	regularyzacja	kontrastywność	strata głowy
grid_0000	balanced_bce	—	—	zbalansowane BCE
grid_0001	+contractive	kontraktywna	—	zbalansowane BCE
grid_0002	+peak_random	—	InfoNCE, permutacja losowa	zbalansowane BCE
grid_0003	+peak_label_invariant	—	InfoNCE, permutacja z ochroną anotacji	zbalansowane BCE
grid_0004	+contractive+peak_label_invariant	kontraktywna	InfoNCE, permutacja z ochroną anotacji	zbalansowane BCE
grid_0005	grid_0004+negw_mukontrastywna	kontraktywna	InfoNCE, permutacja z ochroną anotacji + ważenie negatywów Jac-cardem	zbalansowane BCE
grid_0006	nnpu+contractive+peak_label_invariant	kontraktywna	InfoNCE, permutacja z ochroną anotacji	nnPU

Rekonstrukcja (odległość Massersteina) występuje we wszystkich siedmiu przypadkach.

Kolejność wierszy odpowiada pytaniu “który komponent został dodany”: `grid_0000` to minimalna linia bazowa, `grid_0001` do `grid_0003` dodają do niej dokładnie po jednym komponencie, `grid_0004` łączy dwa pokazane osobno w `grid_0001` i `grid_0003`, `grid_0005` modyfikuje jego człon kontrastywny, a `grid_0006` powtarza kompozycję `grid_0004` z podmienioną stratą głowy.

Wagi członów są stałe we wszystkich ablacjach:

$$\lambda_{\text{rec}} = 1.0, \quad \lambda_{\text{cls}} = 0.2, \quad \lambda_{\text{CAE}} = 0.001, \quad \lambda_{\text{NCE}} = 0.1$$

Uwaga: Wagi nie były strojone per komponent, więc zmierzony efekt każdego z nich jest warunkowy względem tego konkretnego zestawu.

Dane

Tkanką była nerka. Wykorzystałem losowy podzbiór 10% pikseli (≈ 3 GB), dobrany warstwowo z ziarnem 42, przed podziałem na zbiory.

Wejście. Widmo $x \in \mathbb{R}^M$, $M = 1273$ binów. Binowanie liniowe $\Delta m/z = 0.55$ w zakresie $[200, 900]$, agregacja przez sumowanie, normalizacja TIC:

$$\tilde{I} = \frac{I}{\sum I + \varepsilon}$$

Etykiety. Wielo-etykietowy cel $y \in \{0, 1\}^C$, $C = 508$ klas molekula/addukt, z anotacji META-SPACE odwzorowanych na tę samą oś binów co x . Piksele bez zachowanej anotacji są usuwane przed podziałem.

Podział. Grupowy po `dataset_id`, w proporcjach 0.8/0.1/0.1. Przypisywane są całe zbiory źródłowe, nie pojedyncze piksele, co zapobiega wyciekowi między sąsiadującymi pikselami.

Uwaga: Na tym etapie **nie normalizowałem** danych ze względu na analizator. Nie ma to tutaj znaczenia, ponieważ analizator wpływa wyłącznie na położenie cząsteczek na widmie, co ma znaczenie dopiero na etapie anotacji.

Uwaga: Ustawienia danych i podziału są identyczne z analizą rekonstrukcji.

Uwaga: Stosuje oddzielnie zbiór testowy i walidacyjny, **ponieważ checkpointy są liczone względem zbioru walidacyjnego**, zatem nie jest to zbiór niewidoczny podczas treningu.

Protokół treningowy

Jedna wspólna faza, wszystkie cztery człony optymalizowane łącznie, bez rozgrzewki ani osobnego dostrajania.

parametr	wartość
epoki	15
rozmiar batcha	64
optymalizator	AdamW, lr = 10^{-3} , weight decay 10^{-4}
przycinanie gradientu	norma 5.0
wczesne zatrzymanie	cierpliwość 10
checkpoint	przywrócenie najlepszego wyniku walidacyjnego
powtórzenia	5

Wczesne zatrzymanie nie zadziałało w żadnym z 35 przebiegów, każdy wykonał pełne 15 epok.

Powtórzenie r używa tych samych pochodnych ziaren podziału, kolejności danych i inicjalizacji we wszystkich siedmiu ablacjach, więc porównywane pary różnią się wyłącznie kompozycją straty.

Teoria

W tej części opisuje teorie która sugeruje nam pewne wyniki. Jeżeli jakieś wyniki są nie zrozumiałe tutaj znajdują się odpowiedzi.

Zachęcałbym to przeczytania punktów (#TODO - tutaj wstawić odnośniki do tego że to jest sfera, oraz do tych wstępów z podstawowych problemów.), ponieważ na ich podstawie można zrozumieć większość problematyki. Do pozostałych punktów, są odnośniki w odpowiednim miejscu analizy i są zestawione wnioski.

Notacja

symbol	znaczenie
$x \in \mathbb{R}^M$	widmo wejściowe, $M = 1273$
$a \in \mathbb{R}^L$	wyjście <code>Linear(368, L)</code> , przed normalizacją
$u \in \mathbb{R}^L$	wyjście LayerNormu przed transformacją afiniczną
$z = \gamma \odot u + \beta$	reprezentacja w przestrzeni ukrytej (wyjście enkodera)
$\mathbf{1}$	wektor jedynek w $\mathbb{R}^L$
$A_x = \partial a / \partial x$	Jakobian części enkodera przed normalizacją
$J(x) = \partial z / \partial x$	Jakobian całego enkodera
$g(z) \in \mathbb{R}^{64}$	wyjście projektora, używane wyłącznie przez stratę kontrastyczną
$P = I - \frac{1}{L} \mathbf{1} \mathbf{1}^\top - \frac{1}{L} u u^\top$	rzut na przestrzeń styczną do M

Dodatkowe założenia: $10^{-8} = \varepsilon \ll \sigma^2$ (będziemy to później pomijać).

Motywacje teoretyczne - trening

Charakteryzacja przestrzeni

Ostatecznie będziemy pracować na elipsoidzie $(L - 2)$ -wymiarowej, zanurzonej w $(L - 1)$ wymiarowej podprzestrzeni afinicznej.

$$M \cong S^{L-2}(\sqrt{L}) \subset \mathbb{R}^{L-1}$$

Poniżej wytłumaczenie.

Uwaga: Jest to przeliczone ponieważ się nad tym wcześniej nie zastanawiałem a to jest ważny fragment

Przekształcenia wynikające z architektury

W architekturze po CNN, jest ustawiona warstwa liniowa `Linear(368, L)`, którą następnie: 1. normalizujemy po warstwie (`LayerNorm`)

$$\mu = \frac{1}{L} \sum_{i=1}^L a_i, \quad \sigma^2 = \frac{1}{L} \sum_{i=1}^L (a_i - \mu)^2, \quad u_i = \frac{a_i - \mu}{\sigma}$$

2. przenosimy poprzez odwzorowanie liniowe

$$z = \gamma \odot u + \beta$$

Podprzestrzeń afiniczna (normalizacja po warstwie)

Z 1. otrzymujemy, że u znajduje się na hiperpłaszczyźnie

$$\mathbf{1}^T \cdot u = \underbrace{\sum_{i=1}^L u_i}_{\text{Uwaga 1.1}} = \frac{\sum_{i=1}^L (a_i - \mu)}{\sqrt{\sigma^2 + \varepsilon}} = \frac{\sum_{i=1}^L (a_i) - \overbrace{L \cdot \mu}^{= \sum_{i=1}^L a_i}}{\sqrt{\sigma^2 + \varepsilon}} = 0$$

Uwaga 1.1: Zauważmy że jest to przestrzeń afiniczna, można to potwierdzić poprzez PCA które powinno mieć wymiar 9.

Sprawdzając norme u :

$$\|u\|^2 = \sum_{i=1}^D (u_i)^2 = \frac{\overbrace{\sum_{i=1}^D (a_i - \mu)^2}^{= D\sigma^2}}{\sigma^2 + \varepsilon} = \frac{D\sigma^2}{\sigma^2 + \varepsilon} \xrightarrow{\varepsilon \rightarrow 0} \frac{D\sigma^2}{\sigma^2} = D$$

Otrzymujemy ostatecznie, że nasza podrozmaitość jest postaci

$$M = \left\{ u \in \mathbb{R}^L : \mathbf{1}^\top u = 0, \|u\|^2 = L \right\}$$

co jest definicją sfery $L - 2$ wymiarowej zanurzonej w przestrzeni afinicznej $L - 1$ -wymiarowej:

$$\boxed{M \cong S^{L-2}(\sqrt{D}) \subset \mathbb{R}^{D-1}}$$

Przekształcenie na elipsoide

Następnie przenosimy elementy $u \in S^{L-2}$, przez odwzorowanie afiniczne i otrzymujemy punkt w przestrzeni ukrytej

$$z = \gamma \odot u + \beta$$

Dla $\gamma_i \neq 0$ jest to afiniczna bijekcja.

Kara za kontraktywność

Chciałem żeby encoder był stabilny ze względu na output, to jest żeby małe zaburzenia widma x , nie zmieniały znacząco położenia w latencji.

Żeby to spełnić zastosowałem karę Rifai i in. (ICML 2011) w postaci kwadratu normy Frobeniusa Jakobianu enkodera:

$$L_{\text{contractive}}(x) = \left\| \frac{\partial \text{enc}(x)}{\partial x} \right\|_F^2 = \sum_{i=1}^L \sum_{m=1}^M \left(\frac{\partial z_i}{\partial x_m} \right)^2$$

Ma ona sprawić, aby encoder spełniał własność *kontrakcji*

Uwaga: Norma Frobeniusa jest zatem **średnią wrażliwością po wszystkich kierunkach zaburzenia**. Myślałem, że można by zmodyfikować tę funkcję zastępując normę Frobeniusa, normą spektralną, wtedy minimalizujemy błąd w najgorszym kierunku.

Kara działa przeciwnie do rekonstrukcji. Rekonstrukcja wymaga, by z zachowywało informację o x , czyli żeby enkoder rozróżniał widma. Kontraktywność wymaga, by ich nie rozróżniał. Równowaga ustala się tak, że enkoder pozostaje czuły w kierunkach, w których dane faktycznie się zmieniają, a staje się płaski w pozostałych — czyli wzdłuż rozmaitości danych, a nie w poprzek.

Uwaga: Wymaga to, by enkoder był funkcją pojedynczej próbki. Wszystkie normalizacje w architekturze muszą być **LayerNorm**, nie **BatchNorm**, żeby $\partial \text{enc}(x)/\partial x$ **nie zależy** od pozostałych elementów batcha. Wtedy Jakobian jest dobrze określony.

Implementacja

Jawny Jakobian ma rozmiar (B, L, M) , czyli przy $B = 64$, $L = 10$, $M = 1273$ jest to zbyt kosztowne. Stosuję estymator Hutchinsona. Dla losowego v o niezależnych współrzędnych ± 1 zachodzi $\mathbb{E}[vv^\top] = I$, a stąd:

$$\mathbb{E}_v \left[\|J^\top v\|_2^2 \right] = \mathbb{E}_v \left[v^\top J J^\top v \right] = \text{tr} \left(J J^\top \mathbb{E}[vv^\top] \right) = \text{tr} (J J^\top) = \|J\|_F^2$$

Każdy człon $J^\top v$ to jeden iloczyn wektor-Jakobian, czyli jeden przebieg wstecz. Używam 5 prób, więc koszt to 5 przebiegów zamiast $L = 10$ przy jawnym rachunku.

Wpływ normalizacji na interpretację kary

Kara zaproponowana w artykule Rifai i in. działa na enkoderze bez normalizacji, czyli na całej przestrzeni $\mathbb{R}^L$. U nas wyjście enkodera leży na sferze, więc chcę sprawdzić, co ta kara regularyzuje w naszym przypadku.

Jakobian normalizacji

Różniczkując Jacobian, korzystamy z reguły łańcuchowej i otrzymujemy:

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial u} \cdot \frac{\partial u}{\partial a} \cdot \frac{\partial a}{\partial x}$$

Gdzie, trywialne do policzenia są: - $\frac{\partial a}{\partial x}$ - to jest pochodna po CNN + Linear - $\frac{\partial z}{\partial u}$ - to jest γ

Skupiamy się zatem na wyliczeniu $\frac{\partial u}{\partial a}$, gdzie $u_i = (a_i - \mu)/\sigma$, pamiętając, że μ i σ też zależą od a_j oraz pomijając ϵ .

Stosuję regułę ilorazu do $u_i = (a_i - \mu)/\sigma$:

$$\frac{\partial u_i}{\partial a_j} = \frac{\overbrace{\left(\delta_{ij} - \frac{\partial \mu}{\partial a_j}\right)}^{(1)} \sigma - (a_i - \mu) \overbrace{\frac{\partial \sigma}{\partial a_j}}^{(2)}}{\sigma^2}$$

gdzie δ_{ij} to delta Kroneckera.

(1) Pochodna średniej. Z $\mu = \frac{1}{L} \sum_k a_k$ tylko jeden składnik zawiera a_j :

$$\frac{\partial \mu}{\partial a_j} = \frac{1}{L}$$

(2) Pochodna odchylenia. Różniczkuję stronami $\sigma^2 = \frac{1}{L} \sum_k (a_k - \mu)^2$, korzystając z (1):

$$2\sigma \frac{\partial \sigma}{\partial a_j} = \frac{2}{L} \sum_{k=1}^L (a_k - \mu) \left(\delta_{kj} - \frac{1}{L} \right) = \frac{2}{L} \left[(a_j - \mu) - \underbrace{\frac{1}{L} \sum_{k=1}^L (a_k - \mu)}_{=0} \right] = \frac{2}{L} (a_j - \mu)$$

Suma znika, ponieważ odchylenia od średniej sumują się do zera. Po podzieleniu przez 2σ :

$$\frac{\partial \sigma}{\partial a_j} = \frac{a_j - \mu}{L\sigma}$$

Podstawiam (1) i (2) do wyjściowego wyrażenia:

$$\frac{\partial u_i}{\partial a_j} = \frac{(\delta_{ij} - \frac{1}{L})\sigma - (a_i - \mu) \cdot \frac{a_j - \mu}{L\sigma}}{\sigma^2} = \frac{1}{\sigma} \left(\delta_{ij} - \frac{1}{L} - \frac{1}{L} \cdot \frac{(a_i - \mu)}{\sigma} \cdot \frac{(a_j - \mu)}{\sigma} \right)$$

W dwóch ostatnich ułamkach wstawiamy z definicji u , czyli $u_i = (a_i - \mu)/\sigma$ oraz $u_j = (a_j - \mu)/\sigma$. Ostatecznie:

$$\boxed{\frac{\partial u_i}{\partial a_j} = \frac{1}{\sigma} P_{ij}, \quad P_{ij} = \delta_{ij} - \frac{1}{L} - \frac{u_i u_j}{L}}$$

Trzy człony odpowiadają trzem źródłom zależności: - δ_{ij} to wpływ bezpośredni, - $-1/L$ pochodzi od średniej, - $-u_i u_j/L$ od odchylenia.

Działanie P – interpretacja

Zadziałajmy P na dowolny wektor v :

$$(Pv)_i = v_i - \underbrace{\frac{1}{L} \sum_k v_k}_{\text{średnia } \bar{v}} - u_i \cdot \underbrace{\frac{\langle u, v \rangle}{L}}_{\text{składowa wzdłuż } u}$$

Czyli P odejmuje od v dwie rzeczy: jego średnią oraz jego rzut na kierunek u .

Sprawdzam, co P kasuje. Dla $v = \mathbf{1}$:

$$(P\mathbf{1})_i = 1 - 1 - \underbrace{\frac{u_i}{L} \sum_k u_k}_{=0} = 0$$

Dla $v = u$:

$$(Pu)_i = u_i - \underbrace{\bar{u}}_{=0} - \frac{u_i}{L} \underbrace{\|u\|^2}_{=L} = u_i - u_i = 0$$

Natomiast dla v prostopadłego do obu ($\sum_k v_k = 0$ oraz $\langle u, v \rangle = 0$) otrzymuję $Pv = v$.

P jest zatem odwzorowaniem, które zeruje kierunki $\mathbf{1}$ i u , a pozostałe zostawia bez zmian – czyli rzutem ortogonalnym na $\{\mathbf{1}, u\}^\perp$, o rzędzie $L - 2$.

Uwaga: Powyższy wniosek jest oczywisty z tego powodu, że jesteśmy na sferze, służy bardziej do weryfikacji rachunków

Kara mierzy zatem wyłącznie ruch **po powierzchni sfery**, to jest obrót kierunku u , a nie zmianę amplitudy.

Pełna postać

Dokładając transformację afiniczną i część enkodera przed normalizacją:

$$J(x) = \text{diag}(\gamma) \cdot \frac{1}{\sigma} P \cdot A_x \quad \Rightarrow \quad \|J(x)\|_F^2 = \frac{1}{\sigma(x)^2} \|\text{diag}(\gamma) P A_x\|_F^2$$

Widzimy tutaj trzy czynniki, odpowiednio: - czynnik σ (odwrotność), - czynnik γ (skala), - transformacja PA_x (wrażliwość rzutu).

Chcę sprawdzić jak one wpływają i czy są redukowalne.

Analiza czynników: Czynnik $1/\sigma$ - nieredukowalny

Redukowalność

Obecność $1/\sigma^2$ sugeruje, że wystarczy zwiększyć σ , by zmniejszyć karę. Okazuje się, że bez względu na skalowanie, ten parametr nie ulega zmianie.

Rozważmy przeskalowanie $a \rightarrow \lambda a$. Wtedy $\mu \rightarrow \lambda \mu$ oraz $\sigma \rightarrow \lambda \sigma$, natomiast u pozostaje bez zmian, bo licznik i mianownik skalują się jednakowo. Zatem P też się nie zmienia, a $A_x \rightarrow \lambda A_x$. Podstawiając:

$$\|J\|_F^2 \rightarrow \frac{1}{\lambda^2 \sigma^2} \lambda^2 \|\text{diag}(\gamma) P A_x\|_F^2 = \|J\|_F^2$$

Przesunięcie $a \rightarrow a + t\mathbf{1}$ również nic nie daje: σ w ogóle się nie zmienia, a gdyby t zależało od x , dodatkowy człon w A_x byłby proporcjonalny do $\mathbf{1}$, więc P by go skasował.

Zatem otrzymujemy, że J jest pochodną **odwzorowania** $x \mapsto z(x)$, **i jest niezmienniczy względem parametryzacji**.

Interpretacja czynnika $1/\sigma^2$

Kara rośnie odwrotnie proporcjonalnie do σ^2 , więc widma o małym $\sigma(a(x))$ są karane najmocniej. **Ma to uzasadnienie geometryczne**. Kierunek u powstaje przez podzielenie wektora wycenowanego przez jego długość. Gdy σ maleje, dzielimy przez coraz mniejszą liczbę, więc dowolnie małe zaburzenie a potrafi obrócić u o duży kąt. Wysokie σ oznacza natomiast, że kierunek jest wyznaczony stabilnie.

Model minimalizujący karę ma zatem powód, żeby utrzymywać duże σ , czyli wartości przed normalizacją o **dużym rozrzucie współrzędnych**. **Jest to efekt uboczny, ponieważ deklarowanym celem kary była lokalna płaskość enkodera, a nie kontrast kodu**.

Uwaga: Spodziewam się, że rozkład $\sigma(a(x))$ będzie przesunięty w górę w eksperymentach z karą kontrastową względem zwykłego bce. W eksperymentach bez kary kontrastowej, gdzie działa wyłącznie InfoNCE i ważenie Jaccardem, nic nie wywiera nacisku na σ , więc rozkład powinien pozostać na poziomie bce. Odchylenie od tego wzorca **oznaczałoby, że σ jest sterowane czymś innym niż karą**.

Analiza czynników: Czynnik γ - redukowalny

Redukowalność

Znowu sprawdzamy czy modyfikując σ model może zmniejszyć karę, nie wpływając na pozostałe człony straty. Tutaj okazuje się, że model może to kompensować.

Przeskalujemy parametry `LayerNorm` przez $\lambda > 0$:

$$\gamma \rightarrow \frac{\gamma}{\lambda}, \quad \beta \rightarrow \frac{\beta}{\lambda}$$

Cały kod skaluje się wtedy jednorodnie, $z \rightarrow z/\lambda$. Zmienia się więc wejście dekodera, głowy i projektora – i to trzeba skompensować.

Każdy z tych trzech modułów przyjmuje z przez warstwę liniową $Wz + b$, gdzie W i b to jej własne parametry. Zwiększmy w każdej z nich wagę, zostawiając bias:

$$W \rightarrow \lambda W \quad \Rightarrow \quad (\lambda W) \left(\frac{z}{\lambda} \right) + b = Wz + b$$

Wyjście tej warstwy jest identyczne jak przed zmianą, a więc identyczne jest wszystko, co po niej następuje. Rekonstrukcja, logity i projekcje nie zmieniają się, zatem L_{rec} , L_{head} i L_{NCE} też nie.

Sprawdźmy teraz karę. W $J = \text{diag}(\gamma) \cdot \frac{1}{\sigma} P \cdot A_x$ czynniki σ , P i A_x zależą wyłącznie od a , którego nie ruszaliśmy. Zmienia się tylko pierwszy:

$$\|J\|_F \rightarrow \frac{1}{\lambda} \|J\|_F$$

Zatem otrzymujemy, że J **nie jest niezmienniczy względem skali** γ . Biorąc $\lambda \rightarrow \infty$ model wypycha $L_{\text{contractive}}$ do zera, nie płacąc za to nic w pozostałych członach. Jedynym oporem jest weight decay 10^{-4} na powiększonych wagach W .

Interpretacja czynnika γ

Geometrycznie γ to zestaw półosi elipsoidy, na której leży z . Ustala on rozmiar przestrzeni ukrytej, ale nie zmienia rozmieszczenia punktów na sferze u . Ściskanie γ przybliża wszystkie kody do siebie w sensie odległości euklidesowej, natomiast kąty między nimi pozostają identyczne.

Wynika stąd, że kontrakcja uzyskana przez γ jest pozorna. Kara maleje, ale enkoder rozróżnia widma dokładnie tak samo jak wcześniej. Jest to sytuacja odwrotna niż przy czynniku σ , gdzie nacisk kary przekładał się na realną zmianę uwarunkowania normalizacji.

Degeneracja jest przy tym szersza, niż wynika z samego przeskalowania. Podstawiając $\gamma \rightarrow \gamma \odot s$ dla dowolnego dodatniego wektora s i kompensując $W \rightarrow W \text{diag}(1/s)$ w warstwach następnych, otrzymujemy ponownie identyczne wyjścia. Nieidentyfikowalne jest zatem całe γ , czyli L stopni swobody, a nie tylko jego skala.

Ma to konsekwencję dla kształtu γ . Rozpisując normę po współrzędnych:

$$\|J\|_F^2 = \frac{1}{\sigma^2} \sum_{i=1}^L \gamma_i^2 \|(PA_x)_i\|^2$$

gdzie $(PA_x)_i$ to i -ty wiersz. Nacisk kary na γ_i jest więc proporcjonalny do wrażliwości tej konkretnej współrzędnej. Współrzędne reagujące najsilniej na zmiany widma są ściskane najmocniej, co powinno zwiększać rozrzut wartości γ_i .

Parametr β nie występuje w J w ogóle, ponieważ pochodna stałej jest zerem. Przesunięcie elipsoidy jest dla kary niewidoczne.

Uwaga: Spodziewam się, że w eksperymentach z karą kontraktywną $\|\gamma\|$ będzie mniejsze niż w [bce](#), przy jednoczesnym wzroście norm pierwszych warstw dekodera, głowy i projektora. Powinien też wzrosnąć współczynnik uwarunkowania $\kappa = \gamma_{\max}/\gamma_{\min}$, ponieważ nacisk kary jest różny dla różnych współrzędnych. W eksperymentach bez kary kontraktywnej nic nie wywiera nacisku na γ , więc obie wielkości powinny pozostać na poziomie [bce](#).

Sam spadek $\|\gamma\|$ nie rozstrzyga jednak, czy enkoder faktycznie stał się stabilniejszy. Rozstrzyga dopiero zestawienie go z krzywą wrażliwości kątovej: jeżeli $\|\gamma\|$ maleje, a krzywa się nie zmienia, kara została zaspokojona ściskaniem kodu, nie wygładzaniem odwzorowania.

Miara raportowana w analizie

Ze względu na degenerację przez γ nie wyliczam $\|J\|_F$. Zamiast tego liczę wrażliwość na u , czyli po odrzuceniu transformacji afinicznej:

$$S(x) = \frac{1}{\sqrt{L}} \left\| \frac{\partial u}{\partial x} \right\|_F = \frac{\|PA_x\|_F}{\sigma(x)\sqrt{L}}$$

Dzielnik $\sqrt{L}$ wynika stąd, że przemieszczenie styczne du odpowiada przyrostowi kąta $d\theta = \|du\|/\sqrt{L}$, ponieważ promień rozmaitości wynosi $\sqrt{L}$. **Wielkość S mierzy zatem przyrost kąta na jednostkę zaburzenia wejścia i jest wyrażona w tej samej jednostce co metryka przyjęta w analizie.**

W praktyce raportuję wersję empiryczną, nie wymagającą Jakobianu:

$$\varepsilon \mapsto \mathbb{E}_{x,\delta} \left[\angle (u(x), u(x + \varepsilon\|x\|\delta)) \right], \quad \delta \sim \text{Unif}(S^{M-1})$$

Skalowanie zaburzenia przez $\|x\|$ czyni ε wielkością względną, więc krzywa jest odporna zarówno na skalę wejścia, jak i na γ . Jest to jedyna z rozważanych miar pozwalająca porównać modele trenowane z karą kontraktywną i bez niej, ponieważ modele bez kary nie mają powodu utrzymywać γ w tym samym reżimie.

Kontrastywność

Żeby zapewnić że różne widma z tymi samymi anotacjami, będą w podobnym miejscu w przestrzeni stosuje kare kontrastywną.

Stosuję symetryczny InfoNCE (NT-Xent) w wariancie z permutacją obwiedni pików. Dla batcha o rozmiarze B buduję dla każdego widma *podobne widmo* $\tilde{x}$, a strata liczona jest na wyjściu projektora:

$$L_{\text{NCE}} = -\frac{1}{2B} \sum_{i=1}^{2B} \log \frac{\exp(\text{sim}(g_i, g_{\pi(i)})/\tau)}{\sum_{j \neq i} w_{ij} \exp(\text{sim}(g_i, g_j)/\tau)}$$

gdzie sim to podobieństwo cosinusowe znormalizowanych projekcji, $\pi(i)$ to indeks pary pozytywnej, a w_{ij} to waga negatywu (domyślnie 1).

Konstrukcja pary pozytywnej

Żeby sprawdzić czy niezmienniczość klas wpływa na model porównuję dwa warianty doboru pików podlegających permutacji:

- `permutation_random` - permutacja bez względu na anotacje. Jest to kontrola do sprawdzenia czy niezmienniczość wpływa na wyniki.
- `permutation_label_invariant` - permutowane są tylko piki nieanotowane.

Implementacja architektury - strata nie działa bezpośrednio na przestrzeni ukrytej

Bazując na konstrukcji z SimCLR strata liczona jest na $g(z)$, a nie na z . Projektor `Linear(L, L) → LayerNorm → ReLU → Linear(L, 64)` oddziela geometrię wymuszaną przez InfoNCE od przestrzeni używanej przez rekonstrukcję i głowę.

Zastosowana funkcja **wpływa pośrednio na z** . Możemy się zatem spodziewać słabego efektu geometrycznego na przestrzeni ukrytej przy jednoczesnym silnym efekcie na $g(z)$.

Uwaga: Jest to istotne, ponieważ stosując to **bepośrednio na z** konstruowalibyśmy przestrzeń **niezmienniczą**, ze względu na permutacje widm. Rekonstrukcja była by wtedy możliwa (w teorii) tylko dla anotowanych widm.

Weryfikacja wymaga policzenia tych samych miar geometrycznych osobno na z i na $g(z)$.

Uwaga: Projektor zawiera `ReLU` bezpośrednio po `LayerNorm`, czyli działa na wektorze o zerowej sumie. Przy $\beta \approx 0$ oznacza to, że dla każdej próbki zerowana jest istotna część współrzędnych. Warto zweryfikować empirycznie frakcję zer na wyjściu tej warstwy.

Przewidywany wpływ na geometrię

InfoNCE rozkłada się na dwa przeciwstawne człony (Wang i Isola, 2020): przyciąganie par pozytywnych oraz odpychanie wszystkich pozostałych. Prowadzi to do dwóch testowalnych przewidywań:

1. **Niezmienniczość.** Kąt między $u(x)$ a $u(\tilde{x})$ dla pary pozytywnej powinien być mniejszy w modelach kontrastowych. Dla wariantu `label_invariant` przewiduję dodatkowo asymetrię: przesunięcie przy permutacji pików anotowanych powinno być wyraźnie większe niż przy permutacji nieanotowanych.

2. **Ryzyko zapadania wymiarów.** Człon odpychający jest znanym źródłem *dimensional collapse* – koncentracji wariancji w niewielkiej liczbie kierunków. Monitoruję to przez widmo wartości własnych, rangę efektywną i współczynnik partycypacji.

Problem z dużą ilością klas

U nas mamy 508 klas, ich końcowo i tak będzie znacznie więcej. W większości będą one na zerze (#TODO - wstawić później gdzie to w analizie się pojawia).

Problem polega na tym, że interpretowane są one jako **negatywy**. Chciałbym wprowadzić interpretację, że są one **nieoznaczone**, wtedy ustalamy rozkłady prawdopodobieństwa

Ważenie negatywów podobieństwem Jaccarda

Wstęp

Pierwszym rozwiązaniem zmodyfikowanie kontrastywności, poprzez wprowadzenie ważenia tych prawdopodobieństw za pomocą jaccarda.

Standardowy InfoNCE traktuje każdy inny element batcha jako negatyw. W MSI dwa piksele pochodzące z tej samej struktury tkanki mają niemal identyczny zestaw anotacji, więc odpychanie ich od siebie jest fałszywym negatywem.

Wprowadzenie

Obiekt, na którym liczę podobieństwo a wektory anotacji. Każdemu pikselowi i odpowiada binarny wektor $y_i \in \{0, 1\}^C$, $C = 508$, gdzie $y_{i,c} = 1$ oznacza, że molekula c została anotowana w tym pikselu przez METASPACE.

Podobieństwo dwóch pikseli definiuję jako współczynnik Jaccarda tych wektorów:

$$\text{Jaccard}(y_i, y_j) = \frac{|\{c : y_{i,c} = 1 \wedge y_{j,c} = 1\}|}{|\{c : y_{i,c} = 1 \vee y_{j,c} = 1\}|} = \frac{y_i^\top y_j}{\|y_i\|_1 + \|y_j\|_1 - y_i^\top y_j} \in [0, 1]$$

jest liczba molekuł anotowanych w obu pikselach, podzielona przez liczbę molekuł anotowanych w co najmniej jednym z nich.

Uwaga: Mianownik nigdy nie jest zerowy, ponieważ bierzemy tutaj pod uwagę peaki tylko z anotacją. Gwarantuje to, że współczynnik jest zatem dobrze określony dla każdej pary.

Następnie wykorzystując współczynnik Jaccarda definiuje wagę jako:

$$w_{ij} = 1 - (1 - w_{\min}) \cdot \text{Jaccard}(y_i, y_j), \quad w_{\min} = 0.25$$

Poniżej zamieszczam przykłady liczbowe:

sytuacja	Jaccard	w_{ij}
brak wspólnych anotacji	0	1.00 – pełne odpychanie

sytuacja	Jaccard	w_{ij}
połowa wspólnych	0.5	0.625
identyczne zestawy anotacji	1	0.25 — odpychanie stłumione czterokrotnie

Waga dodaje do mianownika InfoNCE, mnożąc składnik odpowiadający parze (i, j) :

$$L_{\text{NCE}} = -\frac{1}{2B} \sum_i \log \frac{\exp(\text{sim}(g_i, g_{\pi(i)})/\tau)}{\underbrace{\sum_{j \neq i, j \neq \pi(i)} w_{ij} \exp(\text{sim}(g_i, g_j)/\tau) + \exp(\text{sim}(g_i, g_{\pi(i)})/\tau)}_{\text{tu działa waga}}}$$

Para pozytywna nie jest ważona, mechanizm dotyczy wyłącznie siły odpychania negatywów.

Ponieważ $w_{ij} > 0$ dla każdej pary, żaden negatyw nie jest usuwany z mianownika.

Zmian interpretacji negatywów w głowie predykcyjnej - nnPU

Wstęp

Drugim rozwiązaniem jest zmiana samej straty głowy. Ważenie Jaccardem działa poprzez działanie na stratę kontrastową, ale nie zmienia interpretacji zera w y . Tutaj zmieniam ją wprost: $y_{i,c} = 0$ traktuję jako **nieoznaczone**, nie jako potwierdzony negatyw.

Metoda pochodzi z pracy Kiryo i in. (NIPS 2017), gdzie sformułowana jest dla klasyfikacji binarnej. Stosuję ją niezależnie dla każdej z $C = 508$ klas.

Oznaczenia

Poniższe wielkości definiuję dla ustalonej klasy c ; dla czytelności pomijam indeks c tam, gdzie nie prowadzi to do niejednoznaczności.

symbol	znaczenie
$f_c(x)$	surowy logit głowy dla klasy c
$\ell(t, y)$	strata poniesiona przy predykcji t , gdy prawdą jest y
π_c	prior klasy — udział pikseli, w których molekula c faktycznie występuje
$p_P(x)$	rozkład widm w pikselach zawierających molekułę c
$p_N(x)$	rozkład widm w pikselach jej niezawierających
$p(x)$	rozkład brzegowy wszystkich widm

symbol	znaczenie
$\mathbb{E}_P[\cdot]$	wartość oczekiwana po pikselach anotowanych dla c ($y_c = 1$)
$\mathbb{E}_U[\cdot]$	wartość oczekiwana po pikselach nieoznaczonych ($y_c = 0$)
$\mathbb{E}_N[\cdot]$	wartość oczekiwana po pikselach faktycznie negatywnych – nieobserwowalna

Uwaga: Kluczowe jest rozróżnienie π_c od obserwowanej częstości anotacji. Jeżeli w 2000 pikseli molekula c jest anotowana w 20, to obserwowana częstość wynosi 0.01, ale $\pi_c > 0.01$, ponieważ **zakładamy, że część pikseli** faktycznie ją zawierających nie przeszła filtru FDR. Gdyby obie wielkości były równe, problem, nastąpiła by anihilacja problemu, który próbuje tu rozwiązać.

Wyprowadzenie

Punktem wyjścia jest ryzyko w klasyfikacji nadzorowanej, gdzie znamy oba zbiory:

$$R_c = \pi_c \underbrace{\mathbb{E}_P [\ell(f_c, 1)]}_{\text{koszt na pozytywach}} + (1 - \pi_c) \underbrace{\mathbb{E}_N [\ell(f_c, 0)]}_{\text{koszt na negatywach}}$$

Pierwszy człon umiemy policzyć, sumując stratę po pikselach anotowanych. Drugiego nie jesteśmy w stanie, ponieważ nie znamy zbioru N . Wynika to z założenia, że piksele o $y_c = 0$ to mieszanina prawdziwych negatywów i pominiętych pozytywów.

Możemy go jednak wyznaczyć pośrednio. Rozkład wszystkich pikseli jest mieszaniną obu klas:

$$p(x) = \pi_c p_P(x) + (1 - \pi_c) p_N(x) \quad \Leftrightarrow \quad (1 - \pi_c) p_N(x) = p(x) - \pi_c p_P(x)$$

Całkując obie strony względem $\ell(f_c, 0)$ otrzymujemy tożsamość między wartościami oczekiwanymi:

$$(1 - \pi_c) \mathbb{E}_N [\ell(f_c, 0)] = \underbrace{\mathbb{E}_U [\ell(f_c, 0)]}_{\text{mieralne}} - \pi_c \underbrace{\mathbb{E}_P [\ell(f_c, 0)]}_{\text{mieralne}}$$

Prawą stronę możemy interpretować jako **wszystkie** nieoznaczone piksele były negatywami, następnie **korygujemy** nadmiar, który definiujemy poprzez π_c , który mówi ile takich oznaczeń wykryć nie powinniśmy. Poprawkę szacuję na pikselach anotowanych, ponieważ one pochodzą z p_P .

Podstawiając, otrzymujemy ryzyko PU złożone wyłącznie z wielkości obserwowalnych:

$$R_c = \pi_c \mathbb{E}_P [\ell(f_c, 1)] + \underbrace{\mathbb{E}_U [\ell(f_c, 0)] - \pi_c \mathbb{E}_P [\ell(f_c, 0)]}_{\text{estymator } (1 - \pi_c) \mathbb{E}_N [\ell(f_c, 0)]}$$

Jest to estymator nieobciążony, ale estymator może być ujemny. Zachodzi to wtedy, gdy dopasuje się do pozytywów treningowych, wtedy $\mathbb{E}_P[\ell(f_c, 0)]$ rośnie i odejmowany człon, przeważa. Minimalizacja prowadzi do rozbieżności

Rozwiązaniem jest wymuszenie nieujemności przez obcięcie:

$$R_c = \pi_c \mathbb{E}_P [\ell(f_c, 1)] + \max(0, \mathbb{E}_U [\ell(f_c, 0)] - \pi_c \mathbb{E}_P [\ell(f_c, 0)])$$

Człon $\max(0, \cdot)$ jest jedyną różnicą względem estymatora nieobciążonego. Obcięcie wprowadza obciążenie, ale zanika ono wykładniczo wraz z liczbą próbek, a estymator pozostaje zgodny.

Uwaga: Obcięcie liczone jest na mini-batchu, nie na całym zbiorze. Jest to górne ograniczenie.

Wynika to z tego, że funkcja $\max$ jest funkcją wypukłą i zachodzi $\max\{0, \frac{1}{N} \sum_i z_i\} \leq \frac{1}{N} \sum_i \max\{0, z_i\}$.

Estymacja priorów

π_c wyznaczam jako obserwowaną częstość anotacji klasy c w splicie treningowym, przemnożoną przez stały mnożnik 1.5 i obciętą do $[10^{-4}, 0.99]$.

Uwaga: Mnożnik jest założeniem o stopniu niedoanotowania zbioru, nie wielkością mierzoną.

W eksperymentach Kiryo i in. zaniżenie π szkodziło bardziej niż zawyżenie, a najlepsze wyniki testowe uzyskiwano przy wartościach nieco powyżej prawdziwego prioru. Mnożnik > 1 bazuje na tej obserwacji, jest wybrany bez żadnej podstawy teoretycznej.

Interpretacja mechanizmu

Zwykle BCE podczas optymalizacji przenosi każdy logit na pozycji nieoznaczonej w stronę negatywu, nnPU wstrzymuje dokładnie π_c tego działa, zakładając, że taki ułamek nieoznaczonych to ukryte pozytywy.

Dla klas rzadkich, gdzie π_c jest małe, obie straty zachowują się niemal tak samo, różnica narasta wraz z różnorodnością klas.

Uwaga: Obu strat nie sumuję. Nakładabyby powodowało byto nakładanie **przeciwnych** gradientów na te same logity: jedna podnosiłaby je o wielkość wynikającą z π_c , druga obniżała o wielkość wynikającą z BCE.

Nie testowałoby to żadnej z dwóch hipotez o znaczeniu brakujących anotacji. Są to więc alternatywne ramiona ablacji, nie składniki.

Relacja do ważenia Jaccardem

Obie metody adresują ten sam problem w różnych miejscach architektury:

	miejsce działania	co zmienia
ważenie Jaccardem	mianownik L_{NCE}	siłę odpychania podobnych pikseli
nnPU	L_{head}	interpretację zera w y

Są zatem niezależne i mogą wystąpić w jednym modelu, badam to aktualnie osobno.

Motywacje teoretyczne - analiza

Omawiam tutaj metryki oraz sposób porównywania modeli w różnych analizach, które uwzględniają podstawy teoretyczne.

Przestrzeń ukryta

Obiekt, na którym liczę miary

Wszystkie miary geometryczne liczę na u , nie na z . Robię to odwracając transformację afiniczną:

$$u = \frac{z - \beta}{\gamma}$$

gdzie γ, β odczytuję z `state_dict` warstwy `LayerNorm`. Dla $\gamma_i \neq 0$ jest to odwzorowanie odwrotne do T , więc odzyskuję dokładnie ten wektor, który zwróciła normalizacja.

Robię to ponieważ: 1. T jest homeomorfizmem, nie zmienia własności przestrzeni. Zmienia natomiast obserwowane odległości, kąty, normy oraz widmo kowariancji, a więc rangę efektywną i współczynnik partycypacji. 2. Bez kanonizacji porównywałbym dodatkowo różnicę wynikającą z odziorowania afinicznego. γ różni się systematycznie między ablacjami, ponieważ otrzymuje gradienty z członów różniących się pomiędzy kombinacjami.

Po kanonizacji wszystkie modele leżą na tej samej podrozmiarowości $S^{L-2}(\sqrt{L})$ i możemy je wiarygodnie porównać.

Uwaga:

Kanonizacja jest konieczna niezależnie od wartości γ , natomiast skalę zniekształcenia, które usuwa, mierzę współczynnikiem uwarunkowania $\kappa = \gamma_{\max}/\gamma_{\min}$.

Wynika to z tego, że $z - z' = \gamma \odot (u - u')$, więc zachodzi $\gamma_{\min}\|u - u'\| \leq \|z - z'\| \leq \gamma_{\max}\|u - u'\|$. Stąd porządek dwóch punktów może się odwrócić tylko wtedy, gdy iloraz ich odległości mieści się w $[1/\kappa, \kappa]$. Dla $\kappa \approx 1$ transformacja jest jednokładnością i nie zmienia niczego liczbowo, dla $\kappa \gg 1$ przetasowuje sąsiedztwa.

Wartość κ raportuję z dwóch powodów. Po pierwsze pozwala ocenić, czy wielkości policzone bez kanonizacji wymagają przeliczenia. Po drugie samo $\|\gamma\|$ jest wynikiem, ponieważ kara

kontraktywna spycha γ w dół, więc porównanie tej wartości między ablacjami jest testem degeneracji skali.

Metryka

Raportuję kąt:

$$\cos \theta = \frac{\langle u, u' \rangle}{L}, \quad \theta \in [0, \pi]$$

Ponieważ wszystkie punkty mają jednakową normę, zachodzi tożsamość

$$\|u - u'\|^2 = 2L(1 - \cos \theta) = 4L \sin^2(\theta/2)$$

Metryka cięciwowa $2\sqrt{L} \sin(\theta/2)$, geodezyjna $\sqrt{L} \theta$ i kosinusowa $1 - \cos \theta$ są zatem ściśle rosnącymi funkcjami θ , a więc przekształcają się jedna w drugą przez rosnącą bijekcję.

Uwaga: Nie jest to konsekwencja równoważności norm na $\mathbb{R}^L$. Równoważność norm gwarantuje jedynie zgodność topologii i nie mówi nic o uporządkowaniu sąsiadów. Powyższa tożsamość jest algebraiczna i obowiązuje wyłącznie przy równości obu norm, czyli na u , a nie na z .

Wybieram θ , ponieważ jest ograniczony i czytelny w stopniach, jest metryką wewnętrzną rozmaitości, oraz nie zawiera czynnika $\sqrt{L}$, przez co pozostaje porównywalny między modelami o różnym rozmiarze przestrzeni ukrytej.

Konsekwencje są: - **Niezmiennicze na wybór metryki** (zależą tylko od porządku odległości): kNN-overlap, kNN-purity, RSA ze Spearmanem, trustworthiness, continuity. - **Zależne od wartości** (metrykę trzeba zadeklarować): średnie odległości, silhouette, RSA z Pearsonem, CKA z jądrem RBF, uniformity, k -means, MDS.

Punkt odniesienia: brak struktury

Dla dwóch niezależnych punktów jednostajnych na S^d zachodzi $\mathbb{E}[\cos \theta] = 0$ oraz $\text{Var}[\cos \theta] = 1/(d+1)$. W kampanii $d = L - 2 = 8$, zatem

$$\text{sd}[\cos \theta] = \frac{1}{3}, \quad \theta \approx 90^\circ \pm 19.5^\circ$$

Empiryczny rozkład o średniej bliskiej zeru i odchyleniu bliskim 0.33 jest nieodróżnialny od jednostajnego, czyli oznacza brak struktury. Odchylenie od tej wartości jest pierwszą liczbą raportowaną w tej analizie.

Analogiczny baseline stosuję dla kNN-overlap: dla dwóch niezależnych zbiorów k sąsiadów z N punktów oczekiwane pokrycie wynosi k/N .

Trzy poziomy porównania

Pytanie “czy przestrzeń ukryta się zmieniła” rozbijam na trzy, ponieważ mierzy się je innymi narzędziami i modele mogą różnić się na jednym poziomie, będąc identyczne na innym.

poziom	pytanie	narzędzie	niezmienniczość
geometria globalna	czy struktura jest ta sama z dokładnością do transformacji	odległość Procrustes, CKA liniowe	obróty, odbięcia, skalowanie izotropowe
sąsiedztwa lokalne	czy te same piksele są blisko siebie	kNN-overlap, trustworthiness, continuity	dowolne przekształcenie zachowujące porządek
zawartość informacyjna	czy da się odczytać to samo	probing, RSA względem etykiet	dowolna bijekcja

Uzupełniając raportuję charakterystyki rozkładu na sferze: widmo wartości własnych, rangę efektywną, współczynnik partycypacji, wymiar wewnętrzny (TwoNN) oraz asymetrię chmury $\|\bar{u}\|^2/L$.

Uwaga: Ograniczenie $\text{tr Cov}(u) = L - \|\bar{u}\|^2$ oznacza stały budżet wariancji. Widmo wartości własnych jest więc czystą alokacją ustalonej puli, co czyni rangę efektywną i współczynnik partycypacji bezpośrednio porównywalnymi między ablacjami, bez dodatkowej normalizacji.

Rangę liniową i wymiar wewnętrzny raportuję osobno, ponieważ mierzą różne rzeczy. Warunek $\mathbf{1}^\top u = 0$ jest liniowy, więc widzi go PCA i daje rangę $L - 1$. Warunek na normę jest nieliniowy, więc PCA go nie wykrywa, a ujawnia się dopiero w estymacji wymiaru wewnętrznego, gdzie sufitem jest $L - 2$.

Predykcja

Rzadkość etykiet wymusza wybór metryk odpornych na próg. Klasy o zerowej liczbie pozytywów w danym splicie nie niosą informacji, a `pos_weight` do 20 przesuwają optymalny próg wyraźnie poniżej 0.5, więc metryki progowe mierzą kalibrację, a nie zdolność dyskryminacyjną.

Przyjmuję zatem:

- 1. Metryki bezprogowe jako główne:** average precision i AUROC. Metryki progowe raportuję pomocniczo, przy progu dobranym na walidacji, osobno dla każdej klasy.
- 2. Baseline all-zero** jako punkt odniesienia dla hamming loss oraz prewalencję klasy jako punkt odniesienia dla average precision.
- 3. Uśrednianie makro wyłącznie po klasach z co najmniej jednym pozytywem** w danym splicie, z jawnym podaniem tej liczby. Uśrednianie po wszystkich $C = 508$ klasach zaniża wynik proporcjonalnie do liczby klas nieobecnych i uniemożliwia porównanie splitów.
- 4. Rozbicie wyników według liczebności klasy**, ponieważ obcięcie `max_positive_weight` do 20 niedowaga klasy rzadkiej, a ich jakość jest osobnym pytaniem niż jakość klas obfitych.

Uwaga: Baseline all-zero jest trywialny, pokazuje jedynie, że model nie jest zdegenerowany. Mocniejszym punktem odniesienia jest regresja logistyczna na surowych M binach, przy tym samym podziale i tej samej stracie. Odpowiada ona na pytanie, czy wąskie gardło o rozmiarze L wnosi cokolwiek, czy tylko traci informację molekularną.

Kontrastywność

Strata liczona jest na $g(z)$, a nie na z , więc jej wpływ na przestrzeń ukrytą jest pośredni i przenoszony wyłącznie przez gradienty płynące wstecz przez projektor. Wszystkie miary geometryczne liczę zatem osobno na u i na $g(z)$. Słaby efekt na u przy silnym na $g(z)$ jest wynikiem zgodnym z architekturą, a nie oznaką, że strata nie działa.

Testem właściwym dla hipotezy z konstrukcji pary pozytywnej jest **wskaźnik selektywności**:

$$\frac{\mathbb{E} \angle (u(x), u(\tilde{x}_{\text{permutacja anotowanych}}))}{\mathbb{E} \angle (u(x), u(\tilde{x}_{\text{permutacja nieanotowanych}}))}$$

Mierzy on wprost to, o co pytam, czyli czy enkoder polega na pikach anotowanych. Miary typu Procrustes i CKA odpowiadają jedynie na pytanie, czy reprezentacja jest inna, co jest warunkiem koniecznym, ale nie wystarczającym.

Uzupełniając raportuję alignment i uniformity, ponieważ InfoNCE rozkłada się dokładnie na te dwa człony, oraz rangę efektywną, ponieważ człon odpychający jest znanym źródłem zapadania wymiarów.

Dla ważenia Jaccardem testem właściwym jest RSA między odległością kątową a odległością Jaccarda, ponieważ strata dosłownie wymusza monotoniczny związek między tymi wielkościami.

Uwaga: Raportuję frakcję par o $w_{ij} < 1$. Wektory anotacji są rzadkie, więc znaczna część par ma Jaccard = 0 i nie podlega ważeniu. Jest to warunek konieczny, żeby mechanizm mógł się w ogóle ujawnić.

Kontraktywność

Nie raportuję $\|J\|_F$, ponieważ jest redukowalna przez skalę γ . Zamiast tego liczę wrażliwość na u , czyli po odrzuceniu transformacji afinicznej:

$$S(x) = \frac{1}{\sqrt{L}} \left\| \frac{\partial u}{\partial x} \right\|_F = \frac{\|PA_x\|_F}{\sigma(x)\sqrt{L}}$$

Dzielnik $\sqrt{L}$ wynika stąd, że przemieszczenie styczne du odpowiada przyrostowi kąta $d\theta = \|du\|/\sqrt{L}$, ponieważ promień rozmaitości wynosi $\sqrt{L}$. Wielkość S mierzy przyrost kąta na jednostkę zaburzenia wejścia i jest wyrażona w tej samej jednostce co metryka przyjęta powyżej.

W praktyce raportuję wersję empiryczną, nie wymagającą Jakobianu:

$$\varepsilon \mapsto \mathbb{E}_{x, \delta} \left[\angle \left(u(x), u(x + \varepsilon \|x\| \delta) \right) \right], \quad \delta \sim \text{Unif}(S^{M-1})$$

Skalowanie zaburzenia przez $\|x\|$ czyni ε wielkością względną, więc krzywa jest odporna zarówno na skalę wejścia, jak i na γ . Jest to jedyna z rozważanych miar pozwalająca porównać modele trenowane z karą i bez niej, ponieważ modele bez kary nie mają powodu utrzymywać γ w tym samym reżimie.

Obok krzywej raportuję rozkład $\sigma(a(x))$ oraz $\|\gamma\|$ i κ , czyli wielkości przewidziane w analizie czynników. Zestawienie ich z krzywą rozstrzyga, czy kara została zaspokojona ścisaniem kodu, czy wygładzeniem odwzorowania.

Skala odniesienia dla różnic między ablacjami

Każde powtórzenie r używa tych samych ziaren podziału, inicjalizacji i kolejności danych we wszystkich siedmiu ablacjach. Wykorzystuję to jako rozkład zerowy: każdą miarę liczę najpierw **między powtórzeniami tej samej ablacji**, a różnicę między ablacjami interpretuję wyłącznie względem tego rozrzutu. Porównania prowadzę parami po powtórzeniu (r vs r).

Uwaga: Przy pięciu powtórzeniach testy istotności mają znikomą moc. Raportuję zatem wielkości efektu i przedziały ufności z bootstrapu, oraz pokazuję wszystkie pięć punktów, a nie samą średnią.

Wyniki

Ogólnie

#TODO

Za małą złożoność modelu

Po dwóch trzech epokach, model zeruje swoje funkcje kosztu, ale nie uogólnia się dobrze, (mamy nadal spory błąd). Ważne jest żeby zobaczyć, czy po tej pierwszej drugiej epoce on nie osiąga dobrych wyników. Tyłok że problem polega na tym że “trenując model” nie podnosimy baselineu w postaci jednej epoki, on jak raz przejdziemy tych wszystkich pixelach to jest już nauczony dobrze.

Rekonstrukcja widma (czy są widoczne różnice)

Umiejętność predykcji modelu

Analiza przestrzeni ukrytej

#TODO - geometria czy jest zachowa itd.

Wstępna analiza

W tej części porównuję modele bazowe oraz sam AE bez głowy predykcyjnej, z podstawową architekturą bce, żebyśmy zrozumieli czym różnią się obydwa modele.

Funkcje kosztu




Figure 1: alt text

Uczenie się modelu

Widzimy, że modele się trenują. Możemy zaobserwować także, że nie ma problemu z genrealizacją, ponieważ wraz ze zmniejszającą się funkcją kosztu na zbiorze treningowym, widzimy także, zmniejszające się wartości na zbiorze walidacyjnym.

Głowa predykcyjna Widzimy, że najlepszy wynik osiągnęła architektura nnPU (jest znacząco lepszy)

Kontrastywność Widzimy, że najlepsze wyniki są osiągnięte przez Jaccard - najlepiej się generalizuje. Może to wynikać z tego, że dokładamy nie pewność do modelu.

Porównanie różnicy pomiedz widmami

Globalna rekonstrukcja




Figure 2: alt text

```
experiment task_id repetition best_checkpoint_epoch validation_masserstein_at_best 0 reconstruction-only (conv1d-ae-32-16-8-latent-... task_000050 0 9 10.691730 1 reconstruction-only (conv1d-ae-32-16-8-latent-... task_000051 1 10 9.868596 2 reconstruction-only (conv1d-ae-32-16-8-latent-... task_000052 2 9 13.391882 3 reconstruction-only (conv1d-ae-32-16-8-latent-... task_000053 3 10 10.522310 4 reconstruction-only (conv1d-ae-32-16-8-latent-... task_000054 4 10 9.684984 5 joint + balanced_bce (15 epochs) task_000000 0 14 31.441209 6 joint + balanced_bce (15 epochs) task_000001 1 15 47.456019 7 joint + balanced_bce (15 epochs) task_000002 2 12 33.068923 8 joint + balanced_bce (15 epochs) task_000003 3 14 27.520899 9 joint + balanced_bce (15 epochs) task_000004 4 13 36.197025
```

```
mean std count experiment joint + balanced_bce (15 epochs) 35.136815 7.563443 5 reconstruction-only (conv1d-ae-32-16-8-latent-10, 10 epochs) 10.831900 1.492680 5
```

Z danych i wykresów związanych z rekonstrukcją, widzimy że score jest gorszy.




Figure 3: alt text




Figure 4: alt text




Figure 5: alt text




Figure 6: alt text

Porównując jednak zdjęcia nie widać tych odchyłeń w sposób znaczący. Możemy zauważyć nawet poprawę. Widać po zbliżeniach, że lokalizacja się poprawiła oraz pożybliśmy się skrajnej wartości. Więcej obrazków w (#TODO - wstawić hiperłącze [assets/experiments/08_26/23_08_26_architecture_predictive/notebooks/part_2_prediction_metrics_bce.ipynb](#))

Uwaga: Tutaj to wspólne spektrum było trochę problematycznie, ponieważ, w samej rekonstrukcji, nie wprowadzałem równomiernego podziału względem ilości pixeli z danego obrazu.

Nie porównywałem najlepszego i najgorszego widma, ponieważ z analizy rekonstrukcji, widzimy, że są one bardzo podobne, różnią się jedynie ilością peaków, co powoduje powstawanie większej ilości obwiedni, które generują dodatkowy błąd.

Uwaga - ważne Na końcu osi m/z w rekonstrukcji pojawia się dodatkowy pik. Wynika on z tego, że normalizacja była źle zdefiniowana, to jest po decoderze nie było normalizacji, przez co mieliśmy rozjazd pomiędzy ilością intensywności.

Mogło to też się przyczynić do onmniejszego score'u massersteina - było za mało *intensywności* dostępnej, co mogło zaniżać stratę (nie mam dobrego formalnego uzasadnienia na to).

Predykcyjność bazowa

Ilość anotacji

Class sparsity on the test split (kidney-architecture-predictive__cfg_529dc0e4494b__grid_0000__rep_00, 508 classes, 4023 pixels)



Figure 7: alt text

Zauważmy, że większość klas ma bardzo małą ilość anotacji,

Contrastive learning

Contractive learning

BRUDNO - schemat analizy

GDZIE PORÓWNUJEMY TE LOSSY

- po najlepszy mmiesjcu to pównać powinniśmy, widać że nnpu ma jednak bardz ouży potencjał jeżeli chodzi o NIE PRZEUCZANIE SIĘ - to jest mocne, bo jak wedy dali bardziej złożony model, to moglibyśmy otrzymać znacznie lepsze.

To jest do zastasnowneia, ale motyw jest tak zżę te niektóre losy bardzo szybko się ucza, więc jest to dosyć problematyczne ze względu na to jak to porówynwac, ponieważ **NIE BĘDZIEMY MIELI** informacji o tym kiedy taki model jest wytriowany (z lossu ternigwoego to nei wynika), ale bazowy błąd jest bardzo duży dla momentu gdzie byśmy to odcieli.

Zatem będziemy brać te modele od momentu “przejęcia” LUB późniejszego, bo w przypadku nnPU nei jest to problematyczne (ustalmy strategie przyjęcia jaką można ustalić po tych analizach)

Jak będziemy to porównywać

Będziemy to porównywać to w ten sposób, że każdy badana cecha (związana z innym komponentem) będzie “główną analizą” i każda główna analiza będzie składa się z “pod analiz”, (każda będzie miała takie same te analizy), podczas porównywania tych rzeczy aj ja będę patrzył na “jedną anlaize w tył”, ponieważ korzystam tutaj z przechoniódsci logiki. ... jeżeli ipornywałe A - B to porównać B z C będą wnioski przechodzić ...

Główne analizy

zastosowanie BCE, porównanie porpzreniedj AE vs BCE

Celem jest sprawdzenie jak zmienia się ttuaj widmo, co jest bazowe w tym momencie, czy klasy pomagają w rekosntrukcji

Dostajemy tutaj także BAZOWY poziom predykcji (do niego będziemy się odnosić w kolejnych analiach)

Regularyzacja kontraktywne

Tutaj będziemy sprawdzając jako sama regularyzacja kontraktywna wpływa na rekonstrukcję widm, oraz jak wpływa na ...

#TODO -ciąg dalszy

Uczenie kontrakcyjne

Porównanie przestrzeni latentnej

Celem tutaj będzie porównania jak przestrzeń latentna zmienia się pomiędzy modelami

Pod analizy

Rekonstrukcja

Będziemy badać jak dana zmiana wpływa na rekonstrukcje widma, będziemy wtedy plotować te best i worst widma na rekonstrukcji, po dwie na kombinacje (z najlepszego modelu wszystko będzie trzeba robić)

Ja przy analizowaniu tego będę porównwał tylko jeden w tył fragment

Predykcja

Będziemy porównywać jak zmienia się predykcja, względem tego jaki model wybierzemy, będziemy porównywać tutaj głównie porównywać metryki jak ja TP FP itd. i potem accuracy precision F1 score'y itd.

Przestrzeń ukryta

WAŻNE - będziemy tutaj porównywać jak zmienia się struktura przestrzeni ukrytej - trzeba by wymyślić, jakiś jednoznaczny sposób na porównywanie tego, żeby jakoś geometrycznie to zachowywać (#TODO - to trzeba przemyśleć i skonstruować) #TODO - teraz

Analiza specjalistyczna

Tutaj będziemy w zależności od problemu porównywać inny obiekt, to jest będziemy sprawdzać cechy charakterystyczne dla analizy (np contractive learning czy odpowiednio to rozróżnić itd.)

#TODO jutro - trzeba dodać analizy contractive z contrastive i bce na predykcji i rekonstrukcji dodać - zrobić następnie nnpu żeby całość porównać - WAŻNE, trzeba tutaj zrobić tak, że dobrze rozumiemy teorię i z teorią to wszystko potwierdzić, więc każę

więc: - od razu będziemy kontynuować tę analizę z porównaniem - od zera spisujemy całą metodologię i wyniki - na bieżąco porównujemy wybrane rzeczy ale to jak będziemy wyniki ścigać bo ogólnie widzimy, że - contractive działa bardzo dobrze - contrastive polepsza ale nie ma znaczenia czy jest label (na predykcji jest trochę różnica ale to musimy doczytać) - trzeba sprawdzić czy contrastive znacznie te wyniki polepsza predykcyjne bo geometrycznie nie ma znaczenia wogóle co się dzieje - czemu to nnpu miał by lepiej działać - jak to zrobimy to wtedy trzeba by podać końcową architekturę i to będzie contractive z contrastive wtedy i teraz czy nnpu czy ten label_bce